

Documento de definición del producto

AirSense MX

Plataforma de monitoreo y predicción de calidad del aire para la Zona Metropolitana del Valle de México

Gustavo Pardo • Antonio Esparza

ITAM — Métodos de Gran Escala — Mayo 2026

AirSense MX es una plataforma digital de monitoreo y predicción de calidad del aire para la Zona Metropolitana del Valle de México (ZMVM). El producto integra datos históricos ambientales, información meteorológica y modelos predictivos para generar pronósticos de contaminación atmosférica y alertas preventivas accesibles para la población.

La motivación detrás de AirSense MX surge del impacto creciente de la contaminación atmosférica en la salud pública y de la limitada accesibilidad de las herramientas actuales de monitoreo ambiental. Aunque existen sistemas oficiales que muestran las condiciones actuales del aire, la mayoría no proporciona pronósticos comprensibles ni herramientas preventivas que permitan anticiparse a eventos críticos de contaminación.

AirSense MX busca cerrar esta brecha mediante el uso de tecnologías de datos, machine learning y servicios cloud para transformar información ambiental compleja en recomendaciones claras, útiles y fáciles de interpretar para cualquier persona.

1. ¿Quién es el cliente o usuario final?

El usuario final de AirSense MX son las personas que viven o trabajan en la Zona Metropolitana del Valle de México (ZMVM), especialmente población vulnerable a la contaminación atmosférica como:

- Personas con asma o enfermedades respiratorias.
- Adultos mayores.
- Niños.
- Personas que realizan actividades al aire libre.
- Usuarios que necesitan planear traslados, ejercicio o actividades diarias dependiendo de la calidad del aire.

También puede ser utilizado por:

- Gobiernos locales.
- Instituciones académicas.
- Investigadores.
- Empresas interesadas en monitoreo ambiental.

El producto está diseñado para usuarios no técnicos, por lo que prioriza simplicidad, claridad visual y explicaciones fáciles de entender.

2. ¿Cuál es el problema u oportunidad que tiene el cliente?

Actualmente, la información de calidad del aire en México suele estar:

- Dispersa.
- Poco accesible.
- Difícil de interpretar.
- Enfocada en datos históricos más que predictivos.
- En la App CDMX solo se tiene el dato de las condiciones del aire del momento, pero no se tiene un pronóstico.

Muchos usuarios solo conocen el estado de la contaminación cuando ya existe una contingencia ambiental o cuando los niveles son peligrosos. La oportunidad consiste en transformar datos ambientales complejos en pronósticos comprensibles y accionables que ayuden a las personas a anticiparse a episodios de mala calidad del aire.

AirSense MX busca resolver:

- Falta de predicción accesible.
- Poca integración de datos meteorológicos y ambientales.
- Baja comprensión del impacto diario de la contaminación.

3. ¿Cuál es el beneficio más importante que entrega el producto?

El beneficio principal es permitir que las personas tomen decisiones preventivas para proteger su salud. AirSense MX entrega:

- Pronósticos de calidad del aire de 1 a 7 días.
- Probabilidad de contingencia ambiental.

- Mensajes claros con semáforo visual fácil de interpretar.

Esto permite que los usuarios:

- Reduzcan exposición a contaminantes.
- Planeen actividades al aire libre.
- Adapten horarios de traslado.
- Tomen decisiones informadas antes de que ocurra un evento crítico.

El producto convierte datos complejos en recomendaciones prácticas y fáciles de entender.

4. ¿Cómo sabemos cuál es la necesidad del cliente?

La necesidad se identificó a partir de varios factores.

Observación del contexto urbano

La Ciudad de México enfrenta problemas recurrentes de contaminación atmosférica y contingencias ambientales que afectan directamente la salud pública.

Validación con datos públicos

La existencia de redes como:

- SIMAT (Sistema de Monitoreo Atmosférico).
- RAMA (Red Automática de Monitoreo Atmosférico).
- REDMET (Red de Meteorología y Radiación Solar).
- Open-Meteo (API meteorológica histórica).

demuestra que existe demanda institucional y social por monitoreo ambiental continuo.

Necesidad de accesibilidad

Aunque existen portales oficiales, muchos usuarios no entienden índices ambientales, contaminantes o implicaciones prácticas para su vida diaria.

Oportunidad tecnológica

Actualmente existen capacidades de machine learning, procesamiento en la nube y modelos predictivos que permiten transformar datos históricos en herramientas preventivas más útiles para la población.

5. ¿Cómo es la experiencia del cliente al usar el producto?

La experiencia está diseñada para ser simple, rápida y clara. El usuario entra a una aplicación web donde puede:

- Consultar el pronóstico ambiental.
- Visualizar tendencias de contaminación.
- Revisar probabilidades de contingencia.
- Recibir explicaciones fáciles de entender.

La interfaz prioriza:

- Lenguaje no técnico.
- Visualizaciones intuitivas.
- Mensajes claros.
- Tiempos de carga rápidos.

Ejemplo de experiencia

- 1 El usuario abre AirSense MX.
- 2 Selecciona su zona o estación cercana.
- 3 Observa el pronóstico de calidad del aire para los próximos días.
- 4 Recibe alertas visuales y explicaciones simples como: “la calidad del aire será mala mañana por altas concentraciones de ozono”.
- 5 Puede tomar decisiones preventivas antes de exponerse.

La meta es que el usuario perciba AirSense MX como una herramienta útil, confiable y fácil de consultar diariamente.

6. ¿Qué funcionalidades incluye AirSense MX?

AirSense MX integra varias funcionalidades organizadas alrededor del flujo de valor del usuario: consultar, anticipar y decidir.

Pronóstico por contaminante

El sistema entrega predicciones diarias para los tres contaminantes con mayor impacto en la salud respiratoria en la ZMVM:

- **Ozono troposférico (O₃):** principal contaminante en temporada seca-cálida.

- **Partículas finas (PM2.5):** partículas que penetran profundamente en el sistema respiratorio.
- **Partículas gruesas (PM10):** partículas suspendidas asociadas a procesos industriales y de tráfico.

Predicción multi-horizonte

Para cada estación de monitoreo y cada contaminante, el sistema genera predicciones para el día siguiente y para los siguientes 3 y 7 días, permitiendo al usuario planear actividades con anticipación.

Intervalos de confianza

Cada pronóstico no es un valor único sino un rango de incertidumbre (cota inferior y superior). Esto comunica al usuario qué tan seguro está el modelo de su predicción, evitando alarmismos cuando hay incertidumbre y dando confianza cuando la hay.

Probabilidad de contingencia

Cada predicción incluye una estimación de qué tan probable es que ese día se cruce el umbral oficial de contingencia ambiental, según el Programa para Contingencias Ambientales Atmosféricas (PCAA) de la Secretaría del Medio Ambiente.

Sistema de semáforo

Para que la información sea inmediatamente legible, cada predicción se traduce a un código visual:

- **Verde:** calidad del aire buena, sin restricciones.
- **Amarillo:** calidad moderada, precaución para grupos sensibles.
- **Naranja:** calidad mala, riesgo para población vulnerable.
- **Rojo:** calidad muy mala, contingencia previsible.

Cobertura geográfica

El sistema cubre las 34 estaciones activas de la red SIMAT distribuidas en las cinco zonas oficiales de la ZMVM (Noroeste, Noreste, Centro, Suroeste, Sureste), permitiendo consultas tanto a nivel zonal como por estación específica.

Contexto e interpretación visual

Los pronósticos se acompañan de contexto visual y textual que traduce los datos técnicos en mensajes accesibles. En lugar de mostrar “O₃ predicho 145 ppb”, la interfaz muestra un semáforo claro con la indicación correspondiente — “calidad mala, riesgo para población vulnerable” — acompañado de la información sobre qué contaminante está elevado y qué precauciones tomar.

7. ¿Qué inteligencia se aplica en el producto?

El núcleo predictivo de AirSense MX está construido sobre modelos de machine learning entrenados con datos reales de la red SIMAT y de Open-Meteo. La aproximación combina ingeniería de datos rigurosa con técnicas modernas de regresión por gradient boosting.

Datos de entrada

El modelo utiliza más de 6.7 millones de observaciones horarias de contaminantes en el periodo 2021 a febrero 2026, además de 1.6 millones de observaciones meteorológicas. Estos datos pasan por un pipeline ETL con arquitectura Medallion (Bronze, Silver, Gold) antes de alimentar al modelo.

Familia de modelos

Se utiliza LightGBM, una implementación moderna de árboles de decisión potenciados por gradiente, configurado con regresión por cuantiles para producir no solo una predicción puntual sino un intervalo de incertidumbre. Se entrenan tres modelos independientes (uno por contaminante) con tres sub-modelos cada uno para los cuantiles 10%, 50% y 90%.

Variables predictoras (features)

El modelo aprende de 55 variables que combinan:

- Mediciones recientes del propio contaminante (rezagos de 1, 3, 7 y 14 días).
- Promedios móviles de los últimos 7 y 30 días.
- Variables meteorológicas: temperatura, humedad, radiación solar, viento, presión atmosférica.
- Estacionalidad: día del año, mes, día de la semana.
- Contaminantes relacionados (por ejemplo, NO₂ como precursor de O₃).

Resultados del modelo

Las métricas obtenidas en el conjunto de prueba (octubre 2025 a febrero 2026) son las siguientes:

Contaminante	Error medio (MAE)	Baseline naive	Mejora
Ozono (O ₃)	16.7 ppb	21.5 ppb	+22.4%
PM2.5	5.5 µg/m ³	7.7 µg/m ³	+28.1%
PM10	9.2 µg/m ³	12.7 µg/m ³	+27.5%

Tabla 1. Desempeño del modelo en el periodo de prueba contra el baseline naive (predicción = último valor observado).

Estas métricas significan que, en promedio, el modelo predice los valores de los contaminantes con un error inferior al que tendría un sistema trivial que asume que mañana será igual que hoy. Las tres mejoras superan ampliamente el umbral mínimo de 10% establecido como criterio de calidad.

Validación contra el PCAA

Para evaluar la utilidad del modelo en su capacidad real de alertar contingencias, se compararon las predicciones con los eventos oficialmente declarados por la Secretaría del Medio Ambiente en el periodo de prueba (4 eventos entre octubre 2025 y febrero 2026):

- **Recall zonal: 50%.** El modelo identifica correctamente la zona donde ocurrirán 2 de cada 4 contingencias.
- **Lead time: 1 día.** Cuando el modelo acierta, lo hace con un día de anticipación, suficiente para que el usuario tome decisiones preventivas.
- **Precisión: 3.3%.** El modelo emite más alertas de las que se materializan, lo que en un contexto de salud pública se considera aceptable: es preferible una falsa alarma a un evento no detectado.

Decisiones técnicas clave

Tres decisiones de diseño respaldan la robustez del sistema:

- **Validación contra un baseline naive.** Antes de aceptar el modelo entrenado, se verifica que supere a una predicción trivial. Esta es una práctica estándar en ML responsable que garantiza que el modelo aporta valor real.
- **Split temporal estricto.** Los datos de entrenamiento (2021-2024), validación (enero a septiembre 2025) y prueba (octubre 2025 a febrero 2026) están separados cronológicamente. Esto evita la fuga de información del futuro al pasado, error común que infla artificialmente las métricas.

- **Documentación de hallazgos metodológicos.** Durante la validación se detectó una inconsistencia entre los reportes oficiales del PCAA y el catálogo SIMAT (algunas estaciones tienen nombres diferentes entre fuentes). Esta inconsistencia se documentó con bandera explícita y no se ocultó al evaluar el modelo.

8. ¿Cómo está diseñada la arquitectura del producto?

AirSense MX está construido sobre Amazon Web Services (AWS) siguiendo principios de separación de responsabilidades, modularidad y reproducibilidad. La arquitectura se organiza en cuatro capas.

Capa 1: Ingesta de datos (Bronze)

Los datos crudos se descargan desde las fuentes públicas (SIMAT, Open-Meteo, PDF del PCAA) y se almacenan sin transformación en Amazon S3, particionados por fuente y por fecha. Esta capa preserva la inmutabilidad del dato original.

Capa 2: Procesamiento y limpieza (Silver)

Los datos crudos se normalizan, validan y enriquecen utilizando AWS Glue y awswrangler. Se convierten códigos especiales a nulos, se ajustan zonas horarias, se unen las observaciones con el catálogo de estaciones para añadir información geográfica (zona, municipio, latitud, longitud). El resultado son tablas Parquet particionadas por año y mes.

Capa 3: Modelado y predicción (Gold)

A partir del Silver se construye un panel diario por estación con 67 columnas que incluyen las observaciones agregadas, variables meteorológicas, rezagos, promedios móviles y etiquetas de contingencia. Este panel alimenta el modelo LightGBM entrenado en Amazon SageMaker utilizando contenedores Docker personalizados (BYOC: Bring Your Own Container). El modelo genera predicciones diarias que se persisten también como Parquet en S3.

Capa 4: Presentación (Streamlit)

La aplicación web desarrollada con Streamlit consume las tablas de predicciones desde S3 y las presenta al usuario final. La aplicación se despliega en infraestructura serverless utilizando ECS Fargate, lo que permite escalabilidad sin gestionar servidores.

Decisiones arquitectónicas relevantes

- **Contenedores en SageMaker (BYOC).** El modelo se entrena dentro de un contenedor Docker que encapsula sus dependencias exactas. Esto garantiza que el código que entrena el modelo en la nube sea idéntico al que se ejecuta localmente durante desarrollo, eliminando errores de reproducibilidad.
- **Adaptador explícito entre Silver y Gold.** Como el ETL de Silver fue desarrollado por una persona del equipo y el modelo por otra, se construyó un módulo adaptador documentado que normaliza los nombres y formatos del Silver al contrato acordado, sin requerir cambios en el ETL upstream. Este es un patrón común en producción donde los equipos de datos y consumidores están desacoplados.
- **Cross-account access controlado.** El equipo trabaja con cuentas AWS separadas. Para compartir datos se utilizó una política de bucket S3 explícita que da permisos mínimos: lectura sobre las capas Gold y dim para el equipo de aplicación, escritura controlada sobre Silver para el equipo de datos. Este es el patrón profesional para colaboraciones entre cuentas.

9. ¿Qué recursos consume el producto y cuánto cuesta operarlo?

Una de las decisiones clave del proyecto fue mantener la operación dentro del nivel gratuito de AWS (Free Tier) o por debajo de un dólar mensual en casos de exceso. La siguiente tabla resume los recursos consumidos:

Recurso	Uso	Costo estimado
Amazon S3 (Bronze, Silver, Gold, modelos)	~500 MB total	< \$0.02 / mes
Amazon ECR (imagen Docker BYOC)	~500 MB imagen	< \$0.05 / mes
SageMaker training (ml.m5.large)	~5 min por entrenamiento	~\$0.01 por corrida
SageMaker batch transform	~5 min por inferencia	~\$0.01 por corrida
ECS Fargate (Streamlit)	1 vCPU, 2 GB RAM	~\$0.50 / mes
Transferencia de datos (S3 → Streamlit)	Lecturas Parquet cache 1h	< \$0.05 / mes

Tabla 2. Recursos consumidos por AirSense MX y estimación de costo operativo.

El costo total estimado para mantener el producto en operación continua durante el periodo del proyecto es inferior a un dólar estadounidense, lo que demuestra que un sistema completo de machine learning en producción puede operarse a costo despreciable cuando se diseña con eficiencia desde el principio.

10. ¿Cuáles son las limitaciones actuales y qué viene en versiones futuras?

AirSense MX v1.0 es una primera versión funcional con capacidades comprobadas, pero también con limitaciones reconocidas que se atenderán en iteraciones futuras.

Limitaciones de la versión 1.0

Subestimación de eventos extremos

El modelo está optimizado para minimizar el error promedio (MAE), lo que naturalmente le hace predecir valores cercanos al comportamiento típico. Como las contingencias ambientales son eventos raros (aproximadamente uno por mes), el modelo tiende a subestimar los picos extremos. Por ejemplo, en un evento donde la concentración real de ozono alcanzó 158 ppb, el modelo predijo 79 ppb.

Dependencia de datos históricos

La versión actual no integra pronósticos meteorológicos del futuro, sino que utiliza datos meteorológicos históricos. Esto limita la precisión de pronósticos a más de 3 días.

Granularidad diaria

El modelo predice valores diarios. No genera pronósticos hora por hora, lo que limita su utilidad para decisiones que requieran detalle horario (por ejemplo, decidir entre salir a correr a las 7 a.m. o a las 6 p.m.).

Roadmap para versiones futuras

Versión 2.0

- Integración de pronósticos meteorológicos en tiempo real desde la API de Open-Meteo Forecast.
- Modelo de clasificación específico para detección de eventos extremos, entrenado con técnicas de oversampling para mejorar la sensibilidad a contingencias.
- Recalibración dinámica del umbral de alerta según contexto estacional.

Versión 3.0

- Modelo horario complementario para decisiones de corto plazo.

- Notificaciones push personalizadas según zona y nivel de sensibilidad del usuario.
- Integración con servicios de salud para registrar exposiciones y correlacionar con síntomas.

11. ¿Cómo se mide el éxito del producto?

El éxito de AirSense MX se mide en tres dimensiones complementarias: técnica, de adopción y de impacto.

Métricas técnicas

- **Error medio absoluto (MAE) del modelo.** Objetivo de mantener mejoras superiores al 20% sobre el baseline naive en cada contaminante.
- **Recall zonal contra el PCAA.** Porcentaje de contingencias oficiales que el modelo logra anticipar con al menos un día. Línea base actual: 50%. Meta v2.0: 75%.
- **Lead time.** Días de anticipación con que el modelo emite la alerta. Actual: 1 día. Meta v2.0: 2-3 días.

Métricas de adopción

- **Usuarios activos semanales.** Medida del uso recurrente de la aplicación.
- **Tiempo en la aplicación.** Indicador de utilidad real, no solo de tráfico.
- **Tasa de consulta antes de actividades al aire libre.** Encuestas para validar que el usuario realmente cambia su comportamiento con base en la información del producto.

Métricas de impacto

- **Decisiones preventivas reportadas.** Porcentaje de usuarios que reportan haber cancelado, pospuesto o modificado una actividad por consultar AirSense MX.
- **Reducción de exposición acumulada.** Métrica calculada como horas de actividad al aire libre evitadas durante eventos de alta contaminación, multiplicado por usuarios alcanzados.

12. Declaración de uso de inteligencia artificial

En el desarrollo de AirSense MX se utilizaron herramientas de inteligencia artificial generativa como apoyo en distintas fases del proyecto. La declaración honesta de este uso es parte integral del entregable.

Herramientas utilizadas

- **Claude** (Anthropic) como asistente de programación para la generación, refactorización y revisión de código durante el desarrollo del proyecto.
- **Claude Code** para tareas de scaffolding y modificación de archivos a gran escala durante el desarrollo.

Cómo se usó la IA

La IA se utilizó como herramienta de aceleración durante el desarrollo del proyecto, no como sustituto del trabajo intelectual. En concreto:

- **Generación de código.** Los módulos de entrenamiento, inferencia, evaluación y ETL fueron escritos en colaboración con el asistente, revisados línea por línea, ajustados al contexto del proyecto y validados con pruebas.
- **Decisiones de diseño.** Todas las decisiones arquitectónicas (modelos por contaminante, regresión por cuantiles, split temporal, contrato de datos, etc.) fueron discutidas y tomadas por los integrantes del equipo. La IA aportó opciones y trade-offs; la decisión fue humana.
- **Documentación.** Este documento fue redactado con apoyo de la IA para la estructura y redacción inicial, revisado y completado por los autores.
- **Sin componentes de IA en el producto final.** El producto AirSense MX en sí mismo no incorpora modelos de lenguaje en línea ni servicios de IA generativa. La inteligencia del producto proviene del modelo de machine learning (LightGBM con regresión por cuantiles) entrenado por el equipo.

Lo que no se hizo

- No se utilizó IA para fabricar datos o resultados.
- No se utilizó IA para escribir conclusiones que no fueran respaldadas por los datos reales del proyecto.
- Las métricas reportadas en este documento provienen de la ejecución real del pipeline con datos del SIMAT, no de estimaciones.

Responsabilidad

Los autores del proyecto asumen plena responsabilidad sobre el contenido entregado, incluido el código, la documentación y los resultados. La IA fue una herramienta; el juicio profesional y las decisiones fueron humanos.